

Hệ thống giám sát mạng và phát hiện tấn công thời gian thực

Nguyễn Đoàn Nhật Minh
Phạm Lê Việt Đức

Học phần: Kỹ thuật và công nghệ dữ liệu lớn

Tổng quan nội dung

- 1 Đặt vấn đề và mục tiêu
- 2 Tập dữ liệu và tiền xử lý dữ liệu
- 3 Công nghệ và công cụ sử dụng
- 4 Huấn luyện mô hình phát hiện tấn công
- 5 Kiến trúc hệ thống real-time
- 6 Kết quả thực nghiệm
- 7 Khó khăn, thách thức và hướng phát triển
- 8 Tổng kết

1. Đặt vấn đề

- Các nhà cung cấp dịch vụ viễn thông vận hành một mạng lưới lớn với lưu lượng truy cập rất cao mỗi ngày. Để đảm bảo chất lượng dịch vụ, hệ thống cần liên tục theo dõi tình trạng hoạt động của mạng và phát hiện sớm các sự cố có thể ảnh hưởng đến người dùng.
- Vấn đề: Cần phát hiện kịp thời các bất thường làm giảm chất lượng dịch vụ và xác định ngay thời gian thực.
- Thách thức: Việc xử lý và phát hiện phải diễn ra ngay lập tức (real-time) để giảm thiểu tối đa thời gian gián đoạn.


1. Mục tiêu

Xây dựng một hệ thống có khả năng thu thập, xử lý, phân tích và cảnh báo lưu lượng mạng bất thường trong thời gian thực.

- **Dữ liệu lớn:** Lưu lượng mạng có số lượng bản ghi lớn, tốc độ sinh dữ liệu cao và cần xử lý liên tục.
- **Phát hiện tấn công:** Cần phân biệt lưu lượng bình thường (Benign) và lưu lượng tấn công (Attack) một cách tự động và chính xác
- **Thời gian phản hồi:** Cảnh báo phải được gửi nhanh để kịp thời xử lý sự cố.
- **Khả năng mở rộng:** Hệ thống cần dễ mở rộng khi số lượng thiết bị, người dùng hoặc traffic tăng lên.

2. Tập dữ liệu

- Tận dụng tập dữ liệu **CIC-IDS2017** .
- Bao gồm lưu lượng mạng bình thường (Benign) và các dạng tấn công phổ biến.
- Dữ liệu chứa 76 cột đặc trưng thống kê luồng mạng với 2,313,810 mẫu.



The screenshot shows the website of the Canadian Institute for Cybersecurity (CIC). The header includes the UNB logo and navigation links: Home, About, Research, Members, Datasets, and Contact Us. The main content area is titled "Intrusion detection evaluation dataset (CIC-IDS2017)". Below the title, there is a paragraph explaining the importance of Intrusion Detection Systems (IDSs) and Intrusion Prevention Systems (IPSs) as defense tools against sophisticated network attacks. It notes that due to the lack of reliable test and validation datasets, anomaly-based intrusion detection approaches are suffering from inconsistent and accurate performance evaluations. A second paragraph mentions that evaluations of existing datasets since 1998 show that most are out of date and unreliable, with some lacking traffic diversity, volumes, or the variety of known attacks, while others anonymize packet payload data, which cannot reflect current trends. Some datasets are also lacking feature sets and metadata.

2. Tiền xử lý dữ liệu

- Xử lý dữ liệu lỗi (NaN hoặc dữ liệu thiếu)
- Mã hóa nhãn: Chuyển đổi nhãn Benign thành 0 và các nhãn còn lại thành 1 để Spark ML có thể xử lý.
- Loại bỏ các cột metadata và cột bị trùng: Fwd Header Length.1, Destination Port, Dst Port.
- Chuyển đổi dữ liệu từ định dạng CSV sang Parquet nhằm tăng tốc độ đọc/ghi và tối ưu hiệu suất xử lý trên Spark.

2. Đặc trưng dữ liệu


Dưới đây là các cột mang ý nghĩa quyết định nhất:

- **Flow Duration:** Thời gian kéo dài của một luồng. Quan trọng để phát hiện các cuộc tấn công ngốn tài nguyên kéo dài (như Slowloris).
- **Total Fwd/Bwd Packets:** Tổng số gói tin gửi đi/nhận lại. Giúp phát hiện tấn công DoS/DDoS khi số lượng gói tin tăng đột biến.
- **Packet Length (Min/Max/Mean):** Thống kê kích thước gói tin. Lưu lượng độc hại thường có phân phối kích thước gói tin bất thường.
- **TCP Flags (SYN, ACK, FIN...):** Số lượng các cờ TCP được kích hoạt. Rất hữu ích để nhận diện kỹ thuật dò quét cổng (PortScan) hoặc SYN Flood.

3. Công nghệ và công cụ sử dụng

- **Apache Kafka và Zookeeper:** Thu thập và phân phối luồng dữ liệu mạng theo thời gian thực.
- **Apache Spark Structured Streaming:** Xử lý dữ liệu streaming theo mô hình micro-batch.
- **PySpark MLlib:** Huấn luyện và triển khai mô hình Random Forest Classifier phân tán.
- **Hadoop HDFS:** Lưu dữ liệu để phân tích và xử lý khi có tấn công
- **InfluxDB:** Lưu trữ các chỉ số giám sát dưới dạng chuỗi thời gian.
- **Grafana:** Trực quan hóa dashboard theo dõi traffic và cảnh báo.
- **Docker:** Container hóa các dịch vụ trong hệ thống.
- **Telegram Bot API:** Gửi cảnh báo bảo mật tức thời tới người dùng.

4. Kiến trúc hệ thống




5. Huấn luyện mô hình


- Mô hình: Random Forest Classifier.
- Công cụ: Spark MLlib
- Kết quả training 10% dữ liệu: F1-Score: 99.70

6. Kết quả thực nghiệm

- Hệ thống hoạt động ổn định, có thể gửi cảnh báo về Telegram nếu phát hiện tấn công.
- Dữ liệu được trực quan hóa với các biểu đồ theo thời gian.



6. Kết quả thực nghiệm



7. Khó khăn và thách thức

- Kiến thức chuyên môn chưa cao.
- Hệ thống mới giả lập bằng cách đọc file Parquet đổ vào Kafka
- Mô hình có thể gây ra báo động giả
- Telegram bot không thể cảnh báo nếu mất mạng

8. Hướng phát triển

- **Mở rộng mô hình phân loại:** Nâng cấp từ phân loại nhị phân sang đa lớp để xác định chính xác từng loại tấn công như Bruteforce, Infiltration, Botnet.
- **Tích hợp mô hình học sâu:** Khảo sát các mô hình chuỗi thời gian như LSTM, GRU trên Spark thông qua TensorFlow on Spark để cải thiện độ chính xác dự báo.
- **Tự động hóa ứng phó:** Phát triển cơ chế tự động khóa IP hoặc ngắt kết nối tạm thời thông qua API tường lửa khi hệ thống phát hiện xâm nhập.

9. Tổng kết

- Xây dựng thành công hệ thống giám sát mạng và phát hiện tấn công thời gian thực end-to-end.
- Hệ thống có khả năng chịu lỗi và mở rộng linh hoạt nhờ kiến trúc tách rời của Kafka và Spark.
- Ứng dụng thực tế cao: Hoàn toàn có thể áp dụng vào thực tế bằng cách thay thế module `kafka_producer` bằng các công cụ bắt gói tin mạng thực (như Wireshark, TShark).

Cảm ơn thầy đã lắng nghe

Phần hỏi đáp (Q&A)